ESA vs PHBench

Decision deck — shortlist final Pedro × Mario

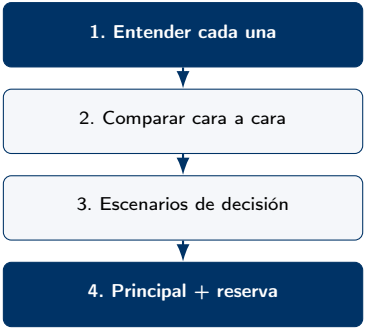
Deep research · Octubre 2026

BAM · Machine Learning & Communication Skills · IE University

11 octubre 2026

Para qué sirve este deck

- Ya acotamos a **dos** opciones finales.
- Aquí comparamos en profundidad, sin jerga innecesaria.
- Objetivo: elegir **1 principal + 1 reserva** esta noche.
- Si una no tiene datos mañana, no puede ser principal.



Las dos finalistas (en una frase)

A · ESA Collision Avoidance

Con avisos tempranos de "casi choque" en órbita, anticipar si el riesgo final será grave — con datos oficiales ESA.

Espacio / deeptech

B · PHBench (Series A)

Con señales públicas del lanzamiento en Product Hunt, ordenar qué startups merecen atención por posible Series A.

VC / ranking

Filtro del curso (igual para las dos)

Datos reales manejables

Métodos del temario (+extra)

Ambición visible (25 %)

Defendible en oral

Marco práctico

Python + scikit-learn + PyTorch · ∼6 semanas · informe + GitHub con historial real · proposal ∼2 páginas **ahora**

Filtro nuestro (Pedro × Mario)

Pedro

Deeptech, física, espacio, quantum. Rechaza lo genérico. Quiere impresionar. No busca el camino fácil.

Afinidad: —/10

Mario

Finanzas y sistemas de recomendación. Quiere originalidad, buenos datos y comparación limpia.

Afinidad: —/10

Vetos

Mario: nada de salud / biomedicina. **Pedro:** nada de proyecto genérico de estudiante (crédito, house prices, bolsa típica).

Finalista A

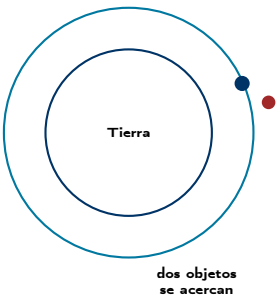
Espacio / ESA

En una frase

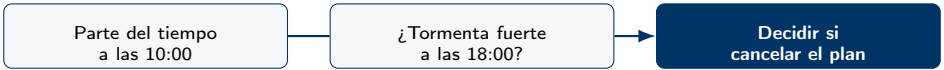
Usamos avisos oficiales de la Agencia Espacial Europea para anticipar si dos objetos en órbita van a acercarse de forma peligrosa.

A · Imagina esto (sin jerga)

- El espacio cercano es una **autopista muy llena**.
- Satélites y basura espacial circulan a miles de km/h.
- Cuando dos objetos se van a cruzar cerca, llega un **aviso** (CDM).
- Ese aviso se actualiza durante días: el riesgo sube o baja.
- Alguien decide: **¿desvío el satélite o no?**



A · Analogía cotidiana



Con el aviso **temprano** (p. ej. $\geq$2 días antes), ¿podemos estimar el riesgo **final**?
Si avisamos bien y pronto: menos maniobras inútiles y menos peligros ignorados.

A · ¿Qué haría el machine learning?

- Hoy hay física + operadores humanos mirando muchos avisos.
- Nosotros: con la secuencia truncada, estimar el riesgo del último aviso.
- Éxito = detectar bien los casos **raros y peligrosos**, no acertar el 99 % fácil.
- Extra de ambición: **calibración**, curvas de aviso temprano, o variables físicas explícitas.

A · Glosario rápido

CDM	Mensaje de "casi choque": una fila con distancia, incertidumbre y riesgo.
Evento	Toda la secuencia de avisos del mismo acercamiento.
TCA	Momento del máximo acercamiento.
High-risk	Umbral operativo típico: $\log_{10} r \geq -6$ (riesgo $\geq 10^{-6}$).
LRP	Baseline fuerte: "usa el último riesgo conocido $\geq$2 días antes".

A · Pregunta de investigación

Principal

Si solo vemos parte de la secuencia (hasta $\geq$2 días antes del TCA), ¿predecimos el riesgo final mejor que reglas simples (LRP)?

Secundarias (elegid 1 como gancho)

(i) ¿Cómo cae la calidad al avisar cada vez antes? (ii) ¿Las probabilidades están bien calibradas? (iii) ¿Hay transferencia entre misiones? (iv) ¿Ayudan variables físicas explícitas?

A · Datos (hechos concretos)

- Zenodo público: `zenodo.org/records/4463683` — **descarga inmediata** (CC BY 4.0).
- Train: 162 634 filas / 13 154 eventos · Test: 24 484 / 2 167.
- $\sim$103 variables por CDM; riesgo en $\log_{10}$.
- High-risk ($r \geq 10^{-6}$): $\sim$3,4 % en train; test enriquecido $\sim$6,9 %.
- Paper: arXiv:2008.03069. Winners: reglas metric-aware o LSTM siamesa — no DL genérico.

A · Baseline que hay que batir (o explicar)



Implicación: no basta con "entrenar un XGBoost". El valor está en el **ángulo** (early-warning, calibración, física, transfer).

A · Qué se intentó ya (competición Kelvins 2019)

- Reto oficial ESA (Kelvins): $\sim$97 equipos; paper Uriot et al. (arXiv:2008.03069).
- La regla ingenua **LRP** (último riesgo $\geq$2 días antes) fue mejor que el 85 % de los equipos.
- Ganadores no fueron "redes profundas genéricas":
  - **1º sesc (Honda RI):** cascada de reglas sobre el riesgo a -2 días + recortes metric-aware.
  - **3º Magpies:** LSTM siamesa para detectar saltos low$\rightarrow$high + ensemble.
- Muchos probaron AutoML / RF / tsfresh y **sobreajustaron**.

A · Qué queda abierto (no es cosplay de leaderboard)

- La competición optimizó una loss rara ($L = \mathrm{MSE}_{HR}/F_2$). Nosotros podemos elegir un claim científico distinto.
- Aún poco explorado con rigor: **curvas de lead-time**, **calibración/UQ**, leave-mission-out, ablación física limpia.
- Oral fuerte: "citamos a sesc/Magpies como baseline; nuestra contribución es X".
- **No** afirmar: "vamos a ganar Kelvins" ni "XGBoost nuevo".

A · Cómo lo haríamos (6 semanas)



- Unidad de análisis: cada **acercamiento completo** (no cada fila suelta).
- Métrica oficial del reto: mezcla F2 (casos graves) + error en high-risk.
- Oral: cuándo ayuda al operador y cuándo falla.

A · Métodos del curso y más allá

Del curso

Regresión / logística · Árboles / boosting · Validación cuidadosa · Ingeniería de variables

Más allá del temario

Serie corta / NN · Calibración · Features orbitales · Opcional: incertidumbre / GP

A · Ángulos de originalidad (elegid uno)

1. Curvas de **early-warning**: calidad vs días de antelación.
2. **Calibración** e uncertainty (no solo score de competición).
3. Transfer entre `mission_id` (el paper documenta shift).
4. Features físicas + ablación limpia.
5. Clasificar high-risk + regresión condicional (como el diseño del score).

A · Encaje Pedro / Mario

Pedro

Máximo: espacio, ESA, física, anti-genérico. Lidera narrativa SSA y variables orbitales.

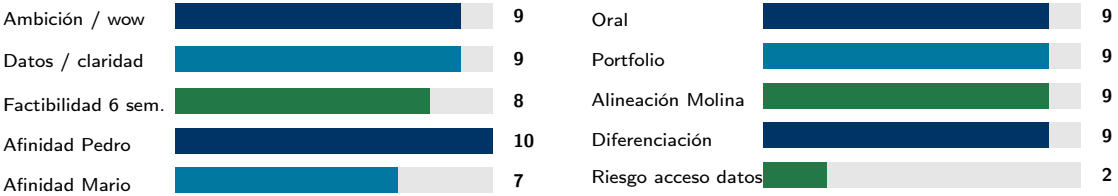
Afinidad: 10/10

Mario

Lidera métricas, rare events, calibración y comparación limpia de modelos.

Afinidad: 7/10

A · Scorecard



Riesgo acceso: 1 = bajo (bueno), 10 = alto (malo). Aquí **2** = Zenodo ya disponible.

A · Pros y contras

Lo bueno

Historia espacial muy fuerte
Datos oficiales, descarga ya
Factible en 6 semanas
Buen oral físico / UQ
Alineado con Molina

Lo malo

Casos graves muy raros
Competición 2019 ya cerrada
Pocas “fotos” visuales
Hay que aportar ángulo propio
Oral puede ser muy técnico

A · Veredicto parcial

Muy fuerte como principal

Ideal si la identidad es “espacio / ESA / deeptech”. Reserva natural: PHBench.

Finalista B

Inversión / VC

En una frase

Usamos señales públicas del día del lanzamiento en Product Hunt para estimar qué productos acaban levantando una ronda Series A.

B · Imagina esto (sin jerga)

- Cada día salen cientos de apps y productos nuevos.
- Casi ninguno consigue una gran ronda (Series A) en $\sim$18 meses.
- Product Hunt es un "escaparate" público: votos, comentarios, equipo...
- Un analista no puede mirarlo todo: necesita una **lista ordenada**.
- Nosotros entrenamos modelos que intentan hacer ese ranking con datos pasados.

B · Analogía cotidiana



Mismo tipo de problema que filtrar muchas solicitudes cuando solo unas pocas son "éxito".
No es predecir si sube o baja una acción en bolsa.

B · ¿Qué haría el machine learning?

- Aprender patrones en lanzamientos antiguos (votos, temas, señales del día).
- Predecir probabilidad de Series A — éxito **rarísimo** ($\sim$1 de cada 127).
- Evaluar como ranking: "de los 50 que marcamos, ¿cuántos acertamos?"
- Cuidado crítico: no usar información del **futuro** (fugas temporales).

B · Glosario rápido

Series A Primera gran ronda institucional de una startup.

Product Hunt Comunidad donde se lanzan y votan productos digitales.

F0.5 Métrica primaria del benchmark: prioriza precisión (mejor pocos aciertos buenos).

Lift@k Cuánto mejor que el azar es tu top-k.

Fuga Variable que "mira al futuro" (p. ej. seguidores medidos años después).

B · Pregunta de investigación

Principal

Con señales del día del launch, ¿qué modelos ordenan mejor los candidatos a Series A en 18 meses, respetando el orden temporal?

Secundarias (elegid 1 como gancho)

(i) Ranking semanal tipo "cola de analista". (ii) Ablación honesta de features con fuga. (iii) Calibración + curvas precisión-capacidad. (iv) ¿Cambian los patrones por ciclo de mercado?

B · Datos (hechos concretos)

- $\sim$67 292 launches; 528 positivos (0,78 %); tabular anonimizado; CC BY 4.0.
- **Sin** tagline/descripción cruda en el release público — no pitch SBERT en week 1.
- Champion test: AP 0,037 ($\sim$4,7$\times$ random), $F_{0,5}$ 0,097 (val inflada).
- HF gated **o** email `benchmark@vela.partners` · paper arXiv:2605.02974.

Riesgo operativo

Sin CSV mañana $\rightarrow$ no primary. Fallback si el gate falla: **VCBench** (no dual-core).

B · Métricas y trampas documentadas

Métricas oficiales

- Primaria: **F0.5**
- También: P@50/100/200, AP, lift

Trampas

- Fuga en `maker_followers`
- Cohort 2025 parcialmente resuelto
- Sesgo: PH $\neq$ universo startups

Hablar de estas trampas en el oral = señal de madurez (no es un bug vuestro: está en el paper).

B · Qué se ha intentado ya (benchmark 2026)

- Benchmark fresco (Ihlamur et al., arXiv:2605.02974) con baselines públicos.
- **Champion:** ensemble de árboles (Top-3) — test AP 0,037 / $F_{0,5}$ 0,097 ($\sim$4,7$\times$ random).
- Baseline oficial: regresión logística (FS4) — test AP 0,024 / $F_{0,5}$ 0,045.
- Dominan: gradient boosting + interacciones + pesos de clase + calibración isotónica.
- LLMs zero-shot (Gemini, números anonimizados): a veces ganan en $F_{0,5}$ puntual, **pierden en AP**; modelo más grande $\neq$ mejor.

B · Qué queda abierto (ángulo propio)

- Holdout **temporal** (train $\leq$2023 $\rightarrow$ eval 2024–25) — lo dejan los autores como future work.
- Calibración hecha bien (ellos calibran en el mismo val que miden).
- Ablación honesta de fuga en followers; lift@k con presupuesto de analista.
- Brazo tabular PyTorch vs árboles; opcional: LLM como "picker" + ML como ranker.
- **No** original: "corrimos XGBoost" ni "los LLMs hacen VC" sin protocolo.

B · Cómo lo haríamos (6 semanas)



B · Métodos del curso y más allá

Del curso
Logística regularizada · Boosting · Validación temporal · Métricas de ranking

Más allá del temario

Calibración · Ablaciones de fuga · Ensambles · Análisis por cohorte / ciclo

B · Ángulos de originalidad (elegid uno)

1. Framing **rank-the-weekly-queue** + lift@k / presupuesto semanal.
2. Ablación honesta de features con fuga temporal.
3. Holdout temporal (train $\leq$2023, eval 2024–25).
4. Calibración anidada + curvas precisión-capacidad.
5. Topics / stats de superficie (no embeddings de texto crudo).

B · Encaje Pedro / Mario

Pedro

VC innovador (no bolsa genérica). Portfolio fuerte. Menos "física", más narrativa de mercado.

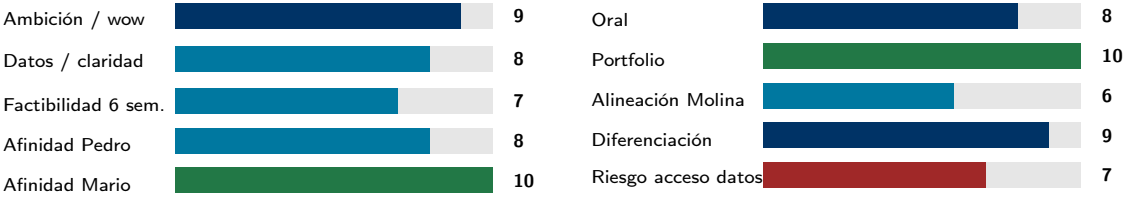
Afinidad: 8/10

Mario

Máximo: finanzas + ranking. Datos claros, comparación limpia, métricas de negocio.

Afinidad: 10/10

B · Scorecard



Riesgo acceso 7/10: HF gated + email. Mitigable si confirmáis acceso esta noche.

B · Pros y contras

Lo bueno

Poco genérico / fresco 2026
Encaja muy bien con Mario
Baselines y leaderboard listos
Historia fuerte en entrevista
Métricas de ranking naturales

Lo malo

Acceso a datos por confirmar
Desbalance brutal (0,78 %)
Fácil contaminar con futuro
Menos deeptech físico
Ética / sesgo en el oral

Muy fuerte si hay datos ya

Ideal si la identidad es "VC / portfolio / ranking". Sin acceso confirmado, mejor como reserva.

Cara a cara · Identidad del proyecto

ESA

"Trabajamos con datos de la Agencia Espacial Europea para avisar antes del riesgo."

PHBench

"Ordenamos la cola semanal de launches para no perder tiempo en early-stage."

Pregunta guía: **¿qué frase queréis decir en la primera frase del oral?**

Cara a cara · Tabla resumen (1–10)

Criterio	ESA	PHBench
Ambición / wow	9	9
Calidad / claridad datos	9	8
Factibilidad 6 semanas	8	7
Afinidad Pedro	10	8
Afinidad Mario	7	10
Articulable con temario	9	9
Defendible en oral	9	8
Portfolio laboral	9	10
Alineación Molina (física / UQ)	9	7
Diferenciación vs genérico	9	8
Riesgo de verse genérico (↑=peor)	2	4
Riesgo de no poder empezar mañana (↑=peor)	2	7

Cara a cara · Quién gana cada eje

Gana ESA

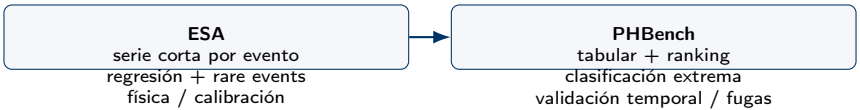
Acceso inmediato · Pedro/espacio · Molina/física/calibración · narrativa ESA · menor fricción esta noche

Gana PHBench

Mario/ranking · portfolio VC · frescura 2026 · métricas de negocio · entrevista "data for investing"

Empate real en ambición y diferenciación. El desempate práctico es: **¿datos en disco mañana?**

Cara a cara · Tipo de ML



Ambas usan el temario (trees, logística, validación). El "extra" es distinto: física/UQ vs ranking/ética de datos.

Cara a cara · Oral (50 %)

ESA — preguntas típicas

- ¿Qué es un CDM?
- ¿Por qué no basta el accuracy?
- ¿Qué es LRP y por qué es fuerte?
- ¿Calibración vs score?

PHBench — preguntas típicas

- ¿Causalidad o correlación?
- ¿Sesgo de Product Hunt?
- ¿Qué fugas evitasteis?
- ¿Por qué F0.5 y no F1?

Cara a cara · Proposal de 2 páginas

- **ESA:** más fácil de escribir ya (links Zenodo + pregunta + baseline LRP + ángulo early-warning).
- **PHBench:** igual de redactable, pero debéis mencionar plan de acceso y métricas F0.5 / P@k.
- En ambos casos: un solo gancho de novedad, no tres.

Cara a cara · Riesgos que matan el proyecto

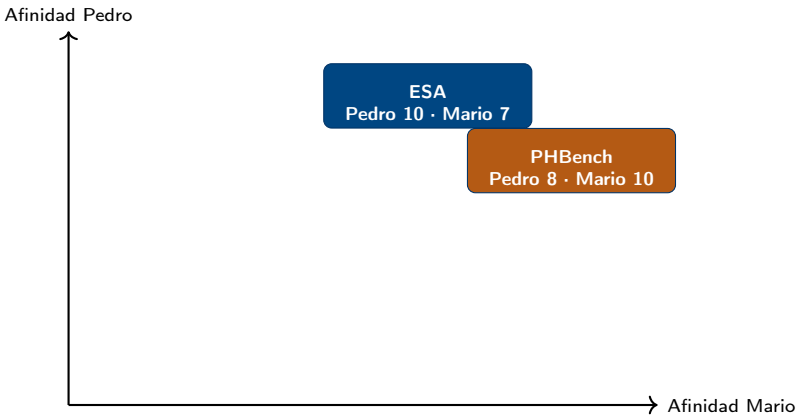
Lo bueno

ESA
Quedarse en "rehacer la competición"
sin ángulo propio
→ oral flojo de originalidad

Lo malo

PHBench
Empezar sin CSV
o ignorar fugas temporales
→ resultados no creíbles

Cara a cara · Visual de trade-offs



ambas son ambiciosas; el eje es identidad

Escenarios — elegid el vuestro

Situación	Elegir
Queréis identidad "espacio / ESA / deeptech"	ESA
Queréis identidad "VC / portfolio / ranking"	PHBench*
Proposal hoy y PHBench aún sin acceso	ESA + PHBench reserva
Mario debe brillar en métricas de negocio	PHBench*
Maximizar alineación Molina (física / UQ)	ESA
Teméis parecer "otra competición Kelvins"	PHBench* o ESA con ángulo claro

*Solo si el acceso a datos está confirmado (HF o email).

Recomendación opinada (research)

Default: ESA primary · PHBench reserva

Confianza ∼72 %. Con peso oral (50 %) + ambición (25 %), ESA gana por margen estrecho pero real.

Por qué

Dato listo · física/UQ · Pedro a tope. Mario no pierde: lidera rare events, calibración y "cuándo el modelo miente".

Vista disidente (∼28 %)

Si el portfolio VC importa más esta noche **y** hay acceso a datos → PHBench primary.

Híbridos a evitar (falsos compromisos)

- ESA + PHBench en **un** proyecto $\rightarrow$ dos RQs, oral diluido.
- Metáfora "Series A $\approx$ riesgo orbital" $\rightarrow$ deck, no ciencia.
- Mitad-mitad "por equidad" $\rightarrow$ equidad de **roles**, no de tema.
- Transformer "porque SOTA" como núcleo $\rightarrow$ ambición falsa.

Compromiso sano

Un primary + un backup en 3 líneas + roles asimétricos claros.

Checklist proposal (gates duros)

- Primary elegido (A o B)
- Backup en 3 líneas
- RQ falsable (1 frase)
- URL datos + estado de acceso
- Unidad de análisis clara
- Métrica rare-events (no accuracy)
- Split sin filtrar futuro
- Un solo ángulo propio
- Ancla temario sklearn + PyTorch
- Roles Pedro / Mario / oral

Reglas de decisión (recordatorio)

- Pedro puede vetar lo **genérico**.
- Mario puede vetar lo **mal definido**.
- Ambición alta, pero ejecutable en 6 semanas.
- Solo **un** gancho de novedad.
- Oral: Mario abre con datos/métricas; Pedro cierra con el porqué.

Scorecard para rellenar juntos

	Opción	Pedro (1–5)	Mario (1–5)	Factib.	¿Principal?
A	ESA Collision Avoidance				
B	PHBench Series A				

Descartad como principal cualquier opción con factibilidad < 3 **o** sin datos esta semana.

Spike de 48 horas (si empatáis)

ESA: Zenodo + 2 plots + baseline LRP

PHBench: pedir acceso HF + email hoy

Regla de desempate

Si en 24h no hay CSV de PHBench $\rightarrow$ ESA primary. Decidir con evidencia, no con vibes.

Plan inmediato tras elegir



La proposal debe incluir

Pregunta precisa · motivación · dataset · exploración preliminar · método inicial · plan de 6 semanas.

Fuentes clave

ESA

- zenodo.org/records/4463683
- kelvins.esa.int/...
- arXiv:2008.03069

PHBench

- phbench.com
- github.com/ihlamury/phbench
- arXiv:2605.02974
- HF: ihlamury/phbench

Comparativa: `research-brief-esa-vs-phbench.md`

Deep A/B: `research-brief-esa-collision-avoidance-deep.md` · `research-brief-phbench-deep.md`

¿ESA o PHBench?

Una principal. Una reserva.

Luego: datos en disco → proposal.