Top 10 opciones de proyecto ML

Pedro × Mario — Decision deck visual y accesible

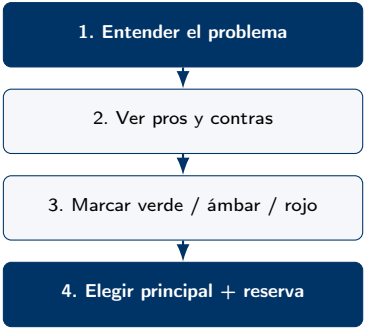
Research brief deep · Octubre 2026

BAM · Machine Learning & Communication Skills · IE University

Octubre 2026

Para qué sirve este deck

- Traduce el research técnico a una conversación de decisión.
- 10 opciones: 5 recomendadas + 5 condicionales.
- Cada opción se explica primero **para alguien de fuera del sector**.
- Objetivo final: elegir **1 principal + 1 reserva**.



Qué pedimos a cada idea (filtro del curso)

Datos reales manejables

Métodos del temario (+extra)

Ambición visible (25 %)

Defendible en oral

Marco práctico

Python + scikit-learn + PyTorch · ∼6 semanas · informe 10–12 páginas + GitHub con historial real

Qué pedimos a cada idea (filtro nuestro)

Pedro

Deeptech, física, robótica, espacio, quantum. Rechaza lo genérico. Quiere un proyecto que impresione. No busca el camino fácil.

Afinidad: 10/10

Mario

Finanzas y sistemas de recomendación. Quiere originalidad, buenos datos y comparación limpia. Dispuesto a leer papers y reproducir ideas.

Afinidad: 8/10

Vetos

Mario: nada de salud / biomedicina / omics. **Pedro:** nada de proyecto genérico de estudiante.

Cómo leer cada bloque de opción



Si no entendéis el problema en las diapositivas “sin jerga” / “analogía”, esa opción aún no está lista para decidir.

El top 10 de un vistazo

Recomendadas

1. Evitar choques entre satélites (ESA)
2. ¿Qué startups llegan a Series A?
3. ¿Los modelos entienden o memorizan?
4. Enseñar física a la red neuronal
5. Ver incendios aunque haya nubes

Condicionales

6. Propiedades de materiales (Matbench)
7. Perfil del founder $\rightarrow$ gran éxito
8. ¿La IA entiende analogías de verdad?
9. Cambios urbanos en dos fotos satélite
10. Reutilizar experiencias de robots

1 · Portada — Evitar choques entre satélites

Recomendada nº 1

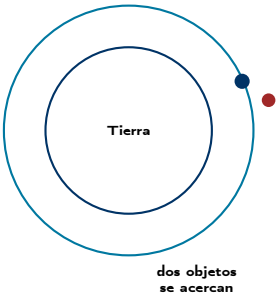
Espacio / ESA

En una frase

Usamos avisos oficiales de la Agencia Espacial Europea para anticipar si dos objetos en órbita van a acercarse de forma peligrosa.

1 · Imagina esto (sin jerga)

- Piensa en el espacio cercano a la Tierra como una **autopista muy llena**.
- Satélites, restos de cohetes y basura espacial circulan a miles de km/h.
- Cuando dos objetos se van a cruzar cerca, llega un **aviso** (como un parte meteorológico del riesgo).
- Ese aviso se actualiza varias veces: el riesgo sube o baja según llegan mejores medidas.
- Alguien tiene que decidir: **¿desvío el satélite o no?**



1 · ¿Qué haría aquí el machine learning?

- Hoy hay física + operadores humanos mirando muchos avisos.
- Nosotros preguntamos: **con los avisos tempranos**, ¿podemos estimar cómo de grave será el riesgo al final?
- Es parecido a: "con el parte de las 10:00, ¿prevemos si la tormenta de las 18:00 será fuerte?"
- Si el modelo avisa bien y pronto, se pueden evitar maniobras innecesarias (gastan combustible) y no ignorar peligros reales.

1 · Palabras que vas a oír (glosario rápido)

CDM Mensaje de "casi choque": una fila de datos con distancia, incertidumbre y riesgo estimado.

Evento Toda la secuencia de avisos del mismo acercamiento (no una sola fila).

TCA Momento del máximo acercamiento.

Desbalance
Casi todos los casos son "poco peligro"; los graves son raros — por eso no vale mirar solo "aciertos totales".

1 · Pregunta de investigación

Pregunta principal

Si solo vemos parte de la secuencia de avisos (por ejemplo, hasta 2 días antes), ¿podemos predecir el riesgo del último aviso mejor que reglas simples?

Pregunta secundaria

¿Ayuda meter variables físicas (distancia, incertidumbre de posición) para reducir falsas alarmas?

1 · Cómo lo haríamos, paso a paso



- Unidad de análisis: cada **acercamiento completo**.
- Éxito = detectar bien los casos raros y peligrosos, no acertar el 99 % fácil.
- Entregable oral: cuándo el modelo ayuda al operador y cuándo se equivoca.

1 · De dónde salen los datos

- Dataset público de la **ESA** (reto Kelvins / Collision Avoidance).
- Miles de acercamientos reales (2015–2019) con muchas variables por aviso.
- Ventaja: no hace falta bajar imágenes de satélite; es tabla + series.
- Reto: hay papers de competición — hay que aportar un **ángulo propio** (avisar antes, calibrar probabilidades, física).

Del curso

Regresión / logística · Árboles / boosting · Validación cuidadosa · Ingeniería de variables

Más allá del temario

Red secuencial pequeña · Calibración de probabilidades · Variables orbitales · Opcional: procesos gaussianos

1 · Por qué encaja con el curso

- Datos reales y poco típicos de estudiante.
- Comparación de modelos natural.
- Limitaciones claras (rareza, incertidumbre).
- Oral defendible: física + métricas.



1 · Por qué encaja con nosotros

Pedro

Le encanta el espacio. Evita proyectos genéricos. Puede liderar la parte física y la historia SSA.

Afinidad: 10/10

Mario

Puede liderar métricas, casos raros, calibración y la comparación limpia de modelos.

Afinidad: 7/10

1 · Pros y contras

Lo bueno

Historia espacial muy fuerte
Datos oficiales ESA
Factible en 6 semanas
Buen oral

Lo malo

Casos peligrosos muy raros
Ya hay resultados de competición
Pocas imágenes "bonitas"
Hay que aportar ángulo propio

1 · Impacto (con los pies en el suelo)

- Mejor aviso temprano $\rightarrow$ menos maniobras inútiles y más seguridad.
- No pretendemos sustituir el control de misión de la ESA: es un estudio académico con datos históricos.

Muy recomendada (prioridad alta)

2 · Portada — ¿Qué startups llegan a Series A?

Recomendada nº 2

Inversión / VC

En una frase

Usamos señales públicas del día del lanzamiento en Product Hunt para estimar qué productos acaban levantando una ronda Series A.

2 · Imagina esto (sin jerga)

- Cada día salen cientos de apps y productos nuevos.
- Casi ninguno consigue una gran ronda de inversión (Series A) en el año y medio siguiente.
- Product Hunt es como un "escaparate" público: votos, comentarios, equipo, descripción...
- Un inversor no puede mirarlo todo: necesita una **lista ordenada** de "esto merece 10 minutos".
- Nosotros entrenamos modelos que intentan hacer ese ranking con datos pasados.

2 · Analogía cotidiana



Es el mismo tipo de problema que filtrar muchas solicitudes cuando solo unas pocas son "éxito".
No es predecir si sube o baja una acción en bolsa.

2 · ¿Qué haría aquí el machine learning?

- Aprender patrones en lanzamientos antiguos (cuántos votos, qué temas, qué texto...).
- Predecir la probabilidad de Series A — sabiendo que el éxito es **rarísimo** ($\sim$1 de cada 130).
- Evaluar con métricas de ranking: "de los 50 que marcamos como prometedores, ¿cuántos acertamos?"
- Cuidado crítico: no usar información del futuro (fugas temporales).

2 · Glosario rápido

Series A Primera gran ronda institucional de una startup.

Product Hunt
Comunidad donde se lanzan productos digitales y se votan.

Desbalance
Casi todo es "no Series A"; acertar el "no" es fácil y engañoso.

PHBench Benchmark abierto (2026) con launches etiquetados.

2 · Pregunta de investigación

Pregunta principal

Con señales del día del launch, ¿qué modelos ordenan mejor los candidatos a Series A en 18 meses, respetando el orden temporal de los datos?

Pregunta secundaria

¿El texto de la descripción aporta algo más allá de los números (votos, ranking del día...)?

2 · Cómo lo haríamos, paso a paso



2 · Datos

- $\sim$67 000 lanzamientos (2019–2025), $\sim$61 variables documentadas.
- Etiquetas de Series A auditadas; hay clasificación pública de referencia.
- Acción inmediata: confirmar acceso al dataset (Hugging Face).

Del curso

Logística regularizada · Árboles / boosting · Validación temporal · Métricas de ranking

Más allá del temario

Representaciones de texto · Ensambles · Calibración · Análisis de qué variables importan

2 · Por qué encaja con el curso

- Original frente a crédito/bolsa típicos.
- Obliga a rigor con eventos raros.
- Muy enseñable en entrevistas.



2 · Por qué encaja con nosotros

Pedro

Le interesa el mundo VC y rechaza finanzas “de siempre”. Buen portfolio.

Afinidad: 8/10

Mario

Finanzas + sistemas de recomendación/ranking. Quiere datos claros y comparación limpia.

Afinidad: 10/10

2 · Pros y contras

Lo bueno

Poco genérico
Encaja con los dos
Baselines listos
Historia fuerte en entrevista

Lo malo

Éxitos muy raros
Acceso a datos por confirmar
Fácil contaminar con futuro
Menos “deeptech físico”

2 · Impacto

Ayudar a priorizar atención en early-stage con datos públicos. No es consejo financiero: es un ranking empírico con error.

Muy recomendada (prioridad alta)

3 · Portada — ¿Los modelos “entienden” o solo memorizan?

Recomendada nº 3

Fundamentos / lenguaje

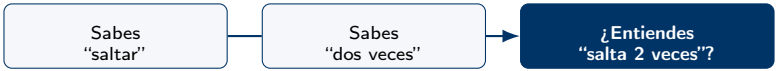
En una frase

Medimos si un modelo que “conoce” una instrucción suelta es capaz de recombinarla en frases nuevas — el famoso fallo tipo “can’t jump”.

3 · Imagina esto (sin jerga)

- A un niño le enseñas el verbo nuevo “dax” y entiende enseguida “dax dos veces”.
- Muchos modelos de IA, en cambio, fallan en esa recombinación.
- No es un debate filosófico vacío: se puede **medir** con un examen diseñado para eso.
- SCAN es ese examen: órdenes simples (“salta”, “anda”, “dos veces”) convertidas en acciones.

3 · Analogía cotidiana



Si solo memorizaste ejemplos raros del examen, puedes aprobar el tipo A y suspender el tipo B.
Eso es **generalización composicional**.

3 · ¿Qué haría aquí el machine learning?

- Entrenar modelos clásicos y redes en un trozo de SCAN.
- Probarlos en el split donde "jump" casi no aparece compuesto.
- Comparar: ¿quién falla y en qué tipo de órdenes?
- Opcional: repetir la idea en un dataset más lingüístico (COGS) para responder "¿SCAN ya está resuelto?".

3 · Glosario rápido

Composición
: Combinar piezas conocidas en algo nuevo.

OOD
: Fuera de lo visto en entrenamiento (el examen "difícil").

SCAN
: Banco de pruebas de órdenes → acciones (Lake & Baroni).

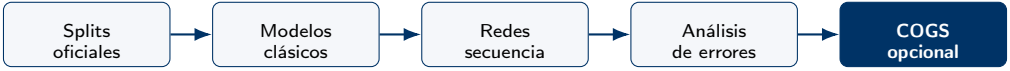
addprim_jump
: Split concreto donde "jump" solo se ve aislado en train.

3 · Pregunta de investigación

Pregunta

Cuando el modelo ve “jump” solo en aislamiento, ¿qué familias de métodos fallan al usarlo dentro de órdenes nuevas, y qué señales del input predicen ese fallo?

3 · Cómo lo haríamos, paso a paso



- SCAN: pequeño, limpio, se corre en un portátil.
- Paper clásico (ICML 2018) = bibliografía fuerte.
- Defensa ante "¿es realista?": es el banco de pruebas estándar de composición, como un test de conducción controlado.

3 · Métodos del curso y más allá

Del curso

N-gramas / TF-IDF · Logística / SVM · Árboles · Validación OOD

Más allá del temario

LSTM/GRU · Transformer pequeño · Análisis de errores · Modelo de lenguaje abierto solo como contraste

3 · Por qué encaja con el curso

- Muy original frente a Kaggle típico.
- La comparación de métodos es el núcleo.
- Oral memorable si se cuenta bien.



3 · Por qué encaja con nosotros

Pedro

Quiere profundidad tipo investigación y temas de abducción / límites de los LLM.

Afinidad: 10/10

Mario

Le gusta NLP y comparar modelos clásicos frente a redes con análisis claro.

Afinidad: 8/10

3 · Pros y contras

Lo bueno

Muy diferenciador
Muy factible
Oral fuerte
Encaja con los dos

Lo malo

Datos sintéticos
Crítica “ya está estudiado”
Menos portfolio espacial/VC
Conviene añadir COGS o diagnóstico

3 · Impacto

Aclarar cuándo un modelo parece inteligente pero no recombina reglas — útil para diseñar evaluaciones honestas.

Muy recomendada (prioridad alta)

4 · Portada — Enseñar física a la red neuronal

Recomendada nº 4

Física + ML

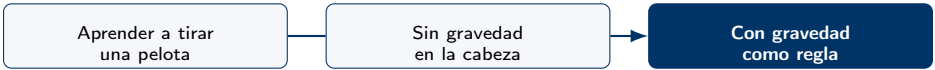
En una frase

Entrenamos modelos que predicen trayectorias, pero obligándolos a respetar reglas físicas (energía, momento), y medimos si extrapolan mejor.

4 · Imagina esto (sin jerga)

- Una red neuronal puede "copiar" una órbita en los datos de entrenamiento.
- Cuando le pides el futuro un poco más lejos, a veces **se desmadra**: la trayectoria deja de parecer física.
- Un ingeniero sabe que ciertas cantidades no deberían "desaparecer" (energía, momento angular).
- La idea: meter esas reglas dentro del aprendizaje, no solo mirar el error numérico.

4 · Analogía cotidiana



Con la regla, suele hacer falta **menos datos** y el modelo aguanta mejor situaciones nuevas.
Condición: debe haber un ancla en datos reales (no solo un ejercicio de libro).

4 · ¿Qué haría aquí el machine learning?

- Comparar: regresión clásica / red normal / red con física (PINN o red hamiltoniana).
- Medir dos cosas: ¿acota bien la posición? ¿respeta la física (poca deriva de energía)?
- Hacer ablación: apagar la física y ver qué se rompe.

4 · Glosario rápido

PINN Red que penaliza incumplir una ecuación física.

HNN Red que aprende una energía y avanza de forma más "física".

Extrapolación Predecir fuera del intervalo visto.

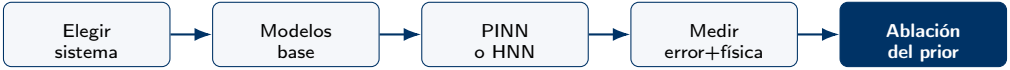
Ablación Quitar una pieza del modelo para ver si importaba.

4 · Pregunta de investigación

Pregunta

¿Un modelo con reglas físicas reduce el error al extrapolar y conserva mejor energía/momento que una red sin esas reglas, con pocos datos ruidosos?

4 · Cómo lo haríamos, paso a paso



4 · Datos posibles

- Simulación controlada + ruido (para entender).
- Ancla real: catálogos orbitales, velocidades radiales de exoplanetas, o un péndulo medido.
- En la proposal hay que nombrar ya cuál será el ancla.

4 · Métodos del curso y más allá

Del curso

Regresión · Redes del curso · Regularización · Validación

Más allá del temario

PINN · Redes hamiltonianas · Residuo con GP · Latentes con significado físico

4 · Por qué encaja con el curso

- Ambición metodológica (no solo accuracy).
- Muy alineado con el estilo del profesor (mecanismo + comparación).
- Oral exigente pero brillante si se domina.



4 · Por qué encaja con nosotros

Pedro

Física al máximo. Puede proponer la capa creativa (ruido, disipación, incertidumbre).

Afinidad: 10/10

Mario

Puede reproducir papers y llevar la comparación rigurosa. Menos "producto de negocio".

Afinidad: 6/10

4 · Pros y contras

Lo bueno

Muy alineado con el profe
Pedro muy motivado
Ablaciones potentes
Historia científica limpia

Lo malo

Riesgo de parecer demo de libro
Mario menos enganchado
Hay que fijar dato real
Menos portfolio VC

4 · Impacto

Mejores predicciones de dinámica con menos datos — idea transferable a espacio, control y ciencia computacional.

Recomendada (con condición)

5 · Portada — Ver incendios desde el satélite (aunque haya nubes)

Recomendada nº 5

Clima / satélites

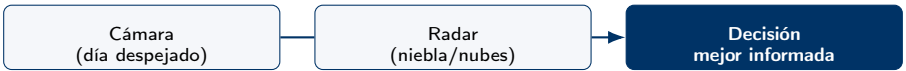
En una frase

Combinamos fotos ópticas y radar de satélites europeos para detectar o mapear fuego, y medimos cuánto aporta cada sensor.

5 · Imagina esto (sin jerga)

- Desde el espacio se ve la Tierra en "fotos" (luz visible e infrarroja).
- Si hay nubes, esas fotos no sirven: el fuego queda tapado.
- Hay otro tipo de satélite que usa **radar**: no "ve" como una cámara, pero atraviesa nubes.
- Pregunta humana: ¿juntar cámara + radar ayuda de verdad a no perder incendios?

5 · Analogía cotidiana



Como conducir con faros normales *y* sensores de aparcamiento: cada uno falla en sitios distintos.

5 · ¿Qué haría aquí el machine learning?

- Calcular índices de vegetación/quemado a partir de bandas espectrales.
- Añadir señales de radar.
- Entrenar clasificadores (árboles, redes) para "quemado / no quemado" o fuego activo.
- Hacer ablaciones: quitar el radar y medir cuánto empeora, sobre todo con nubes.

5 · Glosario rápido

Sentinel-2	Satélite óptico europeo (“cámara” multiespectral).
Sentinel-1	Satélite radar europeo (funciona con nubes).
Burnt area	Zona ya quemada.
Fusión	Usar varias fuentes a la vez, de forma transparente.

5 · Pregunta de investigación

Pregunta

¿Cuánto mejora la detección al fusionar óptico + radar frente a usar solo uno, y qué variables importan más bajo nubes?

5 · Cómo lo haríamos, paso a paso



Empezar con datasets empaquetados (p. ej. Sen2Fire), no con descargas masivas día 1.

- Sen2Fire y similares: recortes ya preparados.
- Alternativas: productos europeos de área quemada.
- Riesgo: si escaláis a cubos enormes, el almacenamiento se come el tiempo.

5 · Métodos del curso y más allá

Del curso

Árboles / boosting · Logística · Ingeniería de variables · Validación espacial

Más allá del temario

CNN / U-Net · Fusión de sensores · Desbalance de clases · Mapas de incertidumbre

5 · Por qué encaja con el curso

- Multi-fuente (valorado en el enunciado).
- Impacto fácil de explicar.
- Figuras muy útiles para Communication Skills.



5 · Por qué encaja con nosotros

Pedro

Satélites y visión le motivan; busca impacto real.
Afinidad: 8/10

Mario

Clima le interesa; puede llevar comparación de modelos y métricas.
Afinidad: 7/10

5 · Pros y contras

Lo bueno

Impacto claro
Historia multi-sensor
Buenas figuras
Encaje razonable de ambos

Lo malo

El pipeline satelital come tiempo
Menos “misión espacial” que ESA
Etiquetas ruidosas
Cuidado con el tamaño de datos

Mejor mapa de fuego en mal tiempo — con humildad: detectar no es lo mismo que explicar causas climáticas.

Recomendada

6 · Portada — ¿Qué tan “conductor” es un material?

Condicional nº 6

Materiales

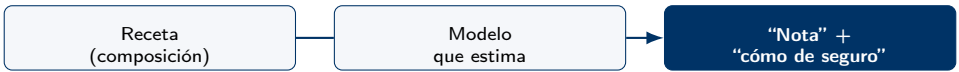
En una frase

Predecimos una propiedad clave de materiales (el band gap) con un banco de datos estándar, midiendo error e incertidumbre.

6 · Imagina esto (sin jerga)

- Para inventar una batería, un chip o un panel, hay que probar muchos materiales.
- Probarlos en laboratorio o simularlos átomo a átomo es **caro y lento**.
- El *band gap* resume, a grandes rasgos, si algo se comporta como metal, semiconductor o aislante.
- Si un modelo estima esa propiedad bien — y dice cuándo duda — se pueden priorizar candidatos.

6 · Analogía cotidiana



Como estimar calorías de un plato por ingredientes: útil si también marcas la incertidumbre.

6 · ¿Qué haría aquí el machine learning?

- Convertir la fórmula química (o estructura) en variables numéricas.
- Comparar regresiones clásicas, árboles y redes.
- Reportar no solo el error medio: también **cuándo** el modelo está perdido.

6 · Glosario rápido

Band gap	Escala de energía relacionada con el comportamiento electrónico.
Matbench	Banco de tareas estándar de ML para materiales.
UQ	Cuantificar incertidumbre (“no solo el número, también la duda”).

6 · Pregunta de investigación

Pregunta

¿Qué combinación de representaciones + modelos minimiza el error de band gap con incertidumbre calibrada, y en qué familias químicas falla más?

6 · Cómo lo haríamos, paso a paso



6 · Datos

- Matbench: tareas limpias y citables.
- Empezar por la versión experimental más pequeña ($\sim$4 600); escalar si sobra tiempo.

6 · Métodos del curso y más allá

Del curso

Regresión · Árboles / boosting · Kernels · Validación anidada

Más allá del temario

Multi-fidelidad · Conformal / GP · Análisis por familia química

6 · Por qué encaja con el curso

- Datos impecables.
- Muy articulable con el temario.
- La incertidumbre aporta ambición sobria.



6 · Por qué encaja con nosotros

Pedro

Ciencia dura OK, pero menos emoción “espacial”. Hace falta el giro de incertidumbre o se queda corto.

Afinidad: 6/10

Mario

Buen encaje con trabajo limpio, comparación y resultados claros.

Afinidad: 7/10

6 · Pros y contras

Lo bueno

Muy factible
Datos excelentes
Fácil de defender
UQ seria

Lo malo

Menos impacto “wow”
Riesgo de parecer solo un ranking
Mario no viene de materials
Pedro puede pedirlo más ambicioso

Acelerar el filtrado de materiales candidatos — la aportación es método + duda calibrada, no un material nuevo.

Condicional — excelente plan B

7 · Portada — ¿El perfil del founder anticipa un gran éxito?

Condicional nº 7

Inversión / founders

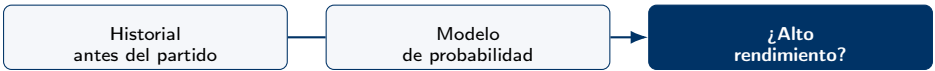
En una frase

Con perfiles anonimizados de fundadores (antes de fundar), intentamos estimar la probabilidad de un éxito empresarial muy grande.

7 · Imagina esto (sin jerga)

- Un inversor early-stage ve currículums y trayectorias, no el futuro.
- Algunas personas tienen historial (estudios, empresas previas, sector...).
- VCBench pregunta: con **solo** lo que se sabía antes de fundar, ¿se puede anticipar un éxito enorme?
- "Éxito enorme" aquí está definido de forma dura (muy alto funding o exit).

7 · Analogía cotidiana



Importante: no mirar el marcador final para "predecir" el marcador final (fuga de información).

7 · ¿Qué haría aquí el machine learning?

- Mezclar variables estructuradas + texto del perfil.
- Comparar modelos y mirar precisión en los positivos (porque un falso "sí" es caro).
- Analizar sesgos: ¿el modelo premia proxies injustos?

7 · Glosario rápido

Founder Persona fundadora de la startup.

Major success
Etiqueta del benchmark (umbral muy alto de funding/exit).

F0.5 Métrica que castiga más los falsos positivos que el recall puro.

7 · Pregunta de investigación

Pregunta

¿Qué modelos maximizan precisión / F0.5 en éxitos mayores, y qué partes del historial importan sin usar información futura?

7 · Cómo lo haríamos, paso a paso



7 · Datos

- $\sim$4 500 perfiles públicos de entrenamiento.
- $\sim$9 % positivos (más manejable que PHBench).
- Hay kit de inicio en GitHub.

7 · Métodos del curso y más allá

Del curso

Logística / árboles · Regularización · Desbalance · Validación

Más allá del temario

Embeddings de texto · Modelo híbrido · Calibración · Revisión de sesgos

7 · Por qué encaja con el curso

- Original frente a crédito genérico.
- Buena data + comparación.
- Ética y limitaciones naturales.



7 · Por qué encaja con nosotros

Pedro

VC innovador OK; útil si PHBench no es accesible a tiempo.
Afinidad: 8/10

Mario

Finanzas + texto. Quiere análisis limpio.
Afinidad: 10/10

7 · Pros y contras

Lo bueno

CSV usable enseguida
Menos extremo que PHBench
Historia VC clara

Lo malo

Solapa con la opción 2
Menos datos
Test privado
Hay que hablar de sesgos

7 · Impacto

Entender límites de “predecir éxito” de personas/empresas: ranking con humildad, no oráculo.

Condicional — respaldo de PHBench

8 · Portada — ¿La IA entiende analogías de verdad?

Condicional nº 8

Lenguaje / abducción

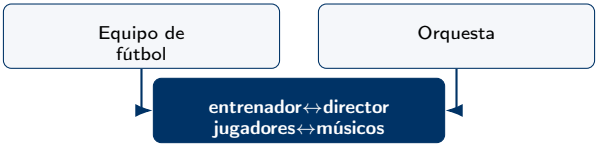
En una frase

Medimos si un modelo no solo elige una analogía "parecida", sino que alinea correctamente las piezas de dos sistemas (mapa estructural).

8 · Imagina esto (sin jerga)

- Decimos: “el átomo es como un sistema solar”.
- No basta con decir “sí, hay analogía”.
- Hay que mapear: Sol$\leftrightarrow$núcleo, planetas$\leftrightarrow$electrones,...
- SCAR es un examen de ese mapeo en analogías científicas.
- Muchos modelos fallan ahí aunque acierten preguntas fáciles de parecido.

8 · Analogía cotidiana



Entender la analogía es construir el diccionario entre piezas, no solo sentir que “se parecen”.

8 · ¿Qué haría aquí el machine learning?

- Representar conceptos con embeddings.
- Proponer emparejamientos (matching) y puntuarlos.
- Comparar con reglas simples de solapamiento de palabras.
- Usar un LLM grande solo como contraste, no como autor del report.

8 · Glosario rápido

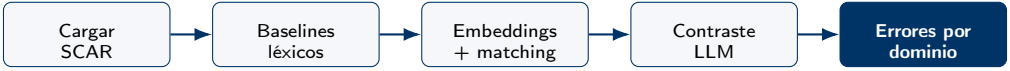
Abducción	Inferir la mejor explicación/estructura a partir de indicios.
Mapping	Correspondencia pieza a pieza entre dos sistemas.
SCAR	Benchmark de analogías científicas con estructura.

8 · Pregunta de investigación

Pregunta

¿Qué representaciones y algoritmos de emparejamiento recuperan mejor los mappings de SCAR, y en qué dominios fallan frente a un LLM en few-shot?

8 · Cómo lo haríamos, paso a paso



8 · Datos

- 400 analogías, 13 dominios, 1600 mappings.
- Tamaño ideal para un proyecto de curso.

8 · Métodos del curso y más allá

Del curso

Kernels / SVM · Árboles · PCA / similitud · Clasificación

Más allá del temario

Embeddings de frases · Matching · Transformer pequeño · LLM solo como contraste

8 · Por qué encaja con el curso

- Muy original.
- Bibliografía rica.
- Oral intelectual fuerte.



8 · Por qué encaja con nosotros

Pedro

Encaja con abducción / límites del lenguaje si el problema es ambicioso.

Afinidad: 9/10

Mario

NLP alto. Puede llevar métodos y análisis.

Afinidad: 9/10

8 · Pros y contras

Lo bueno

Muy temático con abducción
Diferenciador
Dataset manejable

Lo malo

Más pesado que SCAN
Menos portfolio "producto"
Evaluar matching es delicado
Solapa con la opción 3

8 · Impacto

Mejores pruebas de razonamiento analógico — para evaluar modelos con más honestidad.

Condicional — respaldo de SCAN

9 · Portada — ¿Qué cambió en la ciudad entre dos fotos satélite?

Condicional nº 9

Satélite / ciudades

En una frase

Detectamos cambios urbanos comparando dos imágenes Sentinel-2 del mismo lugar en fechas distintas.

9 · Imagina esto (sin jerga)

- Google Earth, pero con propósito científico: dos fotos del mismo barrio, años distintos.
- Queremos un mapa que diga: aquí había campo y ahora hay edificios; aquí abrieron una carretera...
- Eso sirve a urbanismo, seguros, ONGs, gobiernos.
- El peligro académico: el tema está muy visto — sin un giro propio parece proyecto genérico.

9 · Analogía cotidiana



Como el juego de “encuentra las 7 diferencias”, pero automático y sobre ciudades enteras.

9 · ¿Qué haría aquí el machine learning?

- Baseline sencillo: diferencias de índices de vegetación + bosque aleatorio.
- Modelo más flexible: red que mira el par de imágenes a la vez.
- Giro obligatorio: importancia de bandas, incertidumbre, o transfer entre ciudades.

9 · Glosario rápido

Change detection
: Marcar píxeles que cambiaron entre dos fechas.

OSCD
: Dataset pequeño y clásico de cambio urbano con Sentinel-2.

Siamesa
: Red que procesa las dos imágenes de forma emparejada.

9 · Pregunta de investigación

Pregunta

¿Una red emparejada supera a índices + bosque aleatorio en OSCD, y qué bandas importan más si exigimos incertidumbre o transferencia entre ciudades?

9 · Cómo lo haríamos, paso a paso



- 24 pares de imágenes; etiquetas en 14.
- Muy manejable, pero poca muestra $\Rightarrow$ cuidado con conclusiones.

9 · Métodos del curso y más allá

Del curso
Árboles · Ingeniería de variables · Clasificación · Validación

Más allá del temario

CNN emparejada · Ablación de bandas · Incertidumbre · Transfer entre ciudades

9 · Por qué encaja con el curso

- Datos reales de satélite.
- Camino claro curso → PyTorch.
- Figuras fuertes.



9 · Por qué encaja con nosotros

Pedro

Satélites OK, pero necesita un giro o lo verá genérico.
Afinidad: 7/10

Mario

Visión media. Comparación OK. Menos pasión que finanzas.
Afinidad: 6/10

9 · Pros y contras

Lo bueno

Muy factible
Dataset clásico
Buenas visualizaciones
Fácil de explicar

Lo malo

Tema saturado
Pocos pares
Riesgo de verse genérico
Menos diferenciación que ESA/incendios

Monitorizar expansión urbana — el valor real depende del giro (bandas, incertidumbre, transferencia).

Condicional — solo con giro propio

10 · Portada — Reutilizar experiencias de robots

Condicional nº 10

Robótica

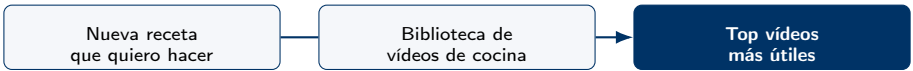
En una frase

En un trozo pequeño de un gran dataset de robots, aprendemos a recomendar demostraciones útiles (o a predecir éxito/fallo) — sin entrenar un modelo gigante.

10 · Imagina esto (sin jerga)

- Hay muchos vídeos/demostraciones de brazos robot haciendo tareas (coger, colocar,...).
- Cuando llega una tarea nueva, ¿qué demostraciones antiguas se parecen más?
- Eso es un **sistema de recomendación** sobre experiencias robot.
- El dataset completo es enorme: si intentáis usarlo entero, el proyecto se come en infraestructura.

10 · Analogía cotidiana



No reentrenáis YouTube entero: elegís un canal (subset) y medís si el ranking tiene sentido.

10 · ¿Qué haría aquí el machine learning?

- Congelar 1–2 subsets concretos (nombres en la proposal).
- Extraer descripciones numéricas de cada demostración.
- Comparar ranking clásico vs embeddings aprendidos.
- Métrica simple: de las K recomendaciones, ¿cuántas eran realmente útiles?

10 · Glosario rápido

OXE	Open X-Embodiment: colección enorme de demos de muchos robots.
Subset	Solo una parte pequeña y nombrada del dataset.
Recall@K	Entre las K primeras recomendaciones, cuántas eran correctas.

10 · Pregunta de investigación

Pregunta

En subsets concretos, ¿representaciones que mezclan lenguaje, estado del robot y acciones recuperan mejores demostraciones que solo visión o variables simples?

10 · Cómo lo haríamos — con freno de emergencia



Regla de parada

Si en 3 días no hay exploración usable por culpa de la infra, se cambia a un dataset de robótica más simple (ver brief largo: TrajAir, ALFA, etc.).

- Nunca el corpus completo (terabytes).
- Candidatos pequeños: Bridge, TOTO, etc.
- Los identificadores del subset deben estar en la proposal.

10 · Métodos del curso y más allá

Del curso

PCA / clustering · Árboles / logística · Autoencoders · Métricas de ranking

Más allá del temario

Codificadores NN · VAE · Fusión multimodal · Recomendador de skills

10 · Por qué encaja con el curso

- Ambición visible (robótica moderna).
- Recommenders = punto fuerte de Mario.
- Solo funciona si el alcance se respeta.



10 · Por qué encaja con nosotros

Pedro

Robótica al máximo; historia cercana a labs de IE sin necesitar el lab.

Afinidad: 9/10

Mario

Recommenders + robótica. Necesita métricas y alcance férreos.

Afinidad: 8/10

10 · Pros y contras

Lo bueno

Mucho atractivo robótica
Encaja con los dos
Historia IE/CyPhy
Recommenders reales

Lo malo

Infra peligrosa
El alcance se infla fácil
Reproducir es frágil
Oral difícil si el pipeline es caos

10 · Impacto

Reutilizar experiencia entre robots/tareas — la idea grande de la robótica "foundation", en versión realista de curso.

Condicional — solo con alcance congelado el día 1

Mapa de identidades: ¿qué historia queréis contar?

Espacio / ESA
→ 1 (res. 4/5)

Inversión / VC
→ 2 (res. 7)

Fundamentos IA
→ 3 (res. 8)

Materiales sólidos
→ 6

Clima / satélites
→ 5 (res. 9)

Robótica
→ 10 solo si alcance fijo

Scorecard para rellenar juntos (1–5)

#	Opción	Afinidad Pedro	Afinidad Mario	Factib. 6 sem.	Curso
1	Satélites ESA				
2	Series A / PHBench				
3	Composición / SCAN				
4	Física en la red				
5	Incendios satélite				
6	Matbench				
7	VCBench founders				
8	Analogías SCAR				
9	Cambio urbano OSCD				
10	Robots OXE (subset)				

Descartad cualquier fila con factibilidad < 3.

Reglas de decisión

- Pedro puede vetar lo **genérico**.
- Mario puede vetar lo **mal definido** o salud.
- Ambición alta, pero ejecutable en 6 semanas.
- Solo **un** gancho de novedad (no inventar método + datos + framing a la vez).
- En el oral: Mario abre con datos/métricas; Pedro cierra con el porqué científico.

Siguiente paso concreto



La proposal (2 páginas) debe incluir

Pregunta precisa · motivación · dataset justificado · exploración preliminar · método inicial · plan realista.

¿Con cuál os quedáis?